

# Busqueda Mediante Hashing

## Analisis de Algoritmos

Universidad Tecnologica Metropolitana

Daniel Abrilot

John Lopez


8 de noviembre de 2013

# Índice

- 1 Introducción y Problemática
- 2 Tabla Hash
- 3 Colisiones
- 4 Conclusiones


# Introducción

- Utilizar un array para almacenar un grupo de objetos requiere un coste lineal con el número de elementos para buscar uno de ellos.
- Desconocer el punto exacto de la estructura donde se almacena el objeto buscado implica realizar una búsqueda..
- ¿Existe la forma de saber donde guardar/buscar un elemento?.




# Introducción

- Utilizar un array para almacenar un grupo de objetos requiere un coste lineal con el número de elementos para buscar uno de ellos.
- Desconocer el punto exacto de la estructura donde se almacena el objeto buscado implica realizar una búsqueda..
- ¿Existe la forma de saber donde guardar/buscar un elemento?.




# Introducción

- Utilizar un array para almacenar un grupo de objetos requiere un coste lineal con el número de elementos para buscar uno de ellos.
- Desconocer el punto exacto de la estructura donde se almacena el objeto buscado implica realizar una búsqueda..
- ¿Existe la forma de saber donde guardar/buscar un elemento?.



# Introducción

- Utilizar un array para almacenar un grupo de objetos requiere un coste lineal con el número de elementos para buscar uno de ellos.
- Desconocer el punto exacto de la estructura donde se almacena el objeto buscado implica realizar una búsqueda..
- ¿Existe la forma de saber donde guardar/buscar un elemento?.



## Problemática Relacionada

- ¿Como se elige la casilla en la que debe ir cada objeto?

Funcion de dispersion asigna un numero o valor hash a un objeto determinado

- $valorHash = hash(x)$ .

- ¿Y si el valor hash excede el tamaño del array?

Uso del operador modulo

- $indiceHash = valorHash \% length(array)$ . es un entero entre  $[0, length(array)-1]$ .

- Si dos objetos reciben el mismo valor se produce una colision

## Problematica Relacionada

- ¿Como se elige la casilla en la que debe ir cada objeto?

Funcion de dispersion asigna un numero o valor hash a un objeto determinado

- $valorHash = hash(x)$ .

- ¿Y si el valor hash excede el tamaño del array?

Uso del operador modulo

- $indiceHash = valorHash \% length(array)$ . es un entero entre  $[0, length(array)-1]$ .

- Si dos objetos reciben el mismo valor se produce una colision



## Problemática Relacionada

- ¿Como se elige la casilla en la que debe ir cada objeto?

Funcion de dispersion asigna un numero o valor hash a un objeto determinado

- $valorHash = hash(x).$

- ¿Y si el valor hash excede el tamaño del array?

Uso del operador modulo

- $indiceHash = valorHash \% length(array).$  es un entero entre  $[0, length(array)-1].$

- Si dos objetos reciben el mismo valor se produce una colision

## Problemática Relacionada

- ¿Como se elige la casilla en la que debe ir cada objeto?

Funcion de dispersion asigna un numero o valor hash a un objeto determinado

- $valorHash = hash(x)$ .

- ¿Y si el valor hash excede el tamaño del array?

Uso del operador modulo

- $indiceHash = valorHash \% length(array)$ . es un entero entre  $[0, length(array)-1]$ .

- Si dos objetos reciben el mismo valor se produce una colision

## Problemática Relacionada

- ¿Como se elige la casilla en la que debe ir cada objeto?

Funcion de dispersion asigna un numero o valor hash a un objeto determinado

- $valorHash = hash(x)$ .

- ¿Y si el valor hash excede el tamaño del array?

Uso del operador modulo

- $indiceHash = valorHash \% length(array)$ . es un entero entre  $[0, length(array)-1]$ .

- Si dos objetos reciben el mismo valor se produce una colision

## Problemática Relacionada

- ¿Como se elige la casilla en la que debe ir cada objeto?

Funcion de dispersion asigna un numero o valor hash a un objeto determinado

- $valorHash = hash(x)$ .

- ¿Y si el valor hash excede el tamaño del array?


Uso del operador modulo

- $indiceHash = valorHash \% length(array)$ . es un entero entre  $[0, length(array)-1]$ .

- Si dos objetos reciben el mismo valor se produce una colision


# La Tabla Hash (I)

- Una tabla Hash es una estructura de datos que pretende la inserción, búsqueda y borrado de elementos en un tiempo constante.
- Para ello la función de dispersión ( $\text{hash}(x)$ ) distribuirá los objetos de forma uniforme a lo largo de la tabla




# La Tabla Hash (I)

- Una tabla Hash es una estructura de datos que pretende la inserción, búsqueda y borrado de elementos en un tiempo constante.
- Para ello la función de dispersión ( $\text{hash}(x)$ ) distribuirá los objetos de forma uniforme a lo largo de la tabla




# La Tabla Hash (I)

- Una tabla Hash es una estructura de datos que pretende la inserción, búsqueda y borrado de elementos en un tiempo constante.
- Para ello la función de dispersión ( $\text{hash}(x)$ ) distribuirá los objetos de forma uniforme a lo largo de la tabla



# La Tabla Hash (I)


- Una tabla Hash es una estructura de datos que pretende la inserción, búsqueda y borrado de elementos en un tiempo constante.
- Para ello la función de dispersión ( $\text{hash}(x)$ ) distribuirá los objetos de forma uniforme a lo largo de la tabla





## La Tabla Hash (II)


- La Tabla Hash debe tener un tamaño relativamente grande para reducir el número de colisiones



Ejemplo de Tabla Hash de tamaño insuficiente. Aunque la función hash distribuya bien los objetos, el tamaño de la tabla afecta directamente a la probabilidad de colisión.

# La Tabla Hash (II)

- La Tabla Hash debe tener un tamaño relativamente grande para reducir el número de colisiones



Ejemplo de Tabla Hash de tamaño insuficiente. Aunque la función hash distribuya bien los objetos, el tamaño de la tabla afecta directamente a la probabilidad de colisión.

## Desventajas de la Tabla Hash


- La Tabla Hash permite realizar las operaciones de búsqueda, inserción y borrado pero existen algunas desventajas.
  - Almacenar  $N$  datos requiere de una Tabla Hash de tamaño  $M \gg N$ , para reducir el número de colisiones.
  - No es posible obtener una secuencia ordenada de sus elementos sin que se genere un coste de tiempo no constante.

## Desventajas de la Tabla Hash

- La Tabla Hash permite realizar las operaciones de búsqueda, inserción y borrado pero existen algunas desventajas.
  - Almacenar  $N$  datos requiere de una Tabla Hash de tamaño  $M \gg N$ , para reducir el número de colisiones.
  - No es posible obtener una secuencia ordenada de sus elementos sin que se genere un coste de tiempo no constante.

## Colisiones : Definición y Gestión


- Una colisión se produce cuando objetos diferentes dan lugar al mismo índice hash
- Objetos  $o1$  y  $o2$ , donde:  $o1 \neq o2 \&\& hash(o1) = hash(o2)$



- Implica un sobrecoste controlar las casillas ocupadas/libres.
- Es complicado evitar colisiones.

## Colisiones : Definición y Gestión


- Una colisión se produce cuando objetos diferentes dan lugar al mismo índice hash
- Objetos  $o_1$  y  $o_2$ , donde:  $o_1 \neq o_2$  &  $hash(o_1) = hash(o_2)$



- Implica un sobrecoste controlar las casillas ocupadas/libres.
- Es complicado evitar colisiones.

## Colisiones : Definición y Gestión


- Una colisión se produce cuando objetos diferentes dan lugar al mismo índice hash
- Objetos  $o_1$  y  $o_2$ , donde:  $o_1 \neq o_2$  &  $hash(o_1) = hash(o_2)$



- Implica un sobrecoste controlar las casillas ocupadas/libres.
- Es complicado evitar colisiones.

## Colisiones : Definición y Gestión

- Una colisión se produce cuando objetos diferentes dan lugar al mismo índice hash
- Objetos  $o_1$  y  $o_2$ , donde:  $o_1 \neq o_2$  &  $hash(o_1) = hash(o_2)$



- Implica un sobrecoste controlar las casillas ocupadas/libres.
- Es complicado evitar colisiones.



## Formas de Resolver las Colisiones



- Resolución Mediante Exploración : Trata de buscar otra posición libre en la tabla para albergar la inserción del elemento.
  - Exploración Lineal : visita la siguiente casilla, si esta libre realiza la inserción sino visita la siguiente.
  - Exploración Cuadrática : visita la casilla  $i^2$  posiciones. si esta libre realiza la inserción sino visita la siguiente.
- Resolución Mediante Encadenamiento Enlazado: En cada posición de la tabla se mantiene una lista enlazada en la que se van insertando los elementos cuyo valor hash les asigna la misma posición.

## Formas de Resolver las Colisiones

- Resolución Mediante Exploración : Trata de buscar otra posición libre en la tabla para albergar la inserción del elemento.
  - Exploración Lineal : visita la siguiente casilla, si esta libre realiza la inserción sino visita la siguiente.
  - Exploración Cuadrática : visita la casilla  $i^2$  posiciones. si esta libre realiza la inserción sino visita la siguiente.
- Resolución Mediante Encadenamiento Enlazado: En cada posición de la tabla se mantiene una lista enlazada en la que se van insertando los elementos cuyo valor hash les asigna la misma posición.



# Hashing Enlazado

- El Hashing Enlazado usa un vector de Listas Enlazadas.
  - Aquellos objetos que reciban un determinado valor de Hash, se insertaran en la lista enlazada correspondiente.




# Hashing Enlazado

- El Hashing Enlazado usa un vector de Listas Enlazadas.
  - Aquellos objetos que reciban un determinado valor de Hash, se insertaran en la lista enlazada correspondiente.




## Ejemplo de uso de la Tabla Hash

- Insertar los elementos  $\{5, 10, 3, 15, 20, 19\}$  en una Tabla Hash de tamaño 10 y con función hash:
  - $\text{hash}(x) = x \% 10$




## Objetos

- ▶ Factor de Carga
  - ▶ Elementos / Capacidad = 6/10




## Ejemplo de uso de la Tabla Hash

- Insertar los elementos  $\{5, 10, 3, 15, 20, 19\}$  en una Tabla Hash de tamaño 10 y con función hash:
  - $\text{hash}(x) = x \% 10$



## Objetos

- ▶ Factor de Carga
  - ▶ Elementos / Capacidad = 6/10



# Rehashing en una Tabla Hash

- Si el Factor de Carga (grado de ocupación) de una Tabla Hash es alto ( $>75\%$ ), el número de colisiones aumenta significativamente.
- Solución : Rehashing
  - Aumentar el tamaño de la tabla para reducir el factor de carga.
- Ventajas
  - Permite mantener un reducido factor de carga para que las principales operaciones (insertar, buscar, eliminar) se realicen en tiempo constante.
- Inconvenientes
  - Requiere construir un nuevo array e insertar nuevamente todos los datos

# Rehashing en una Tabla Hash

- Si el Factor de Carga (grado de ocupacion) de una Tabla Hash es alto ( $>75\%$ ), el numero de colisiones aumenta significativamente.
- Solucion : Rehashing
  - Aumentar el tamaño de la tabla para reducir el factor de carga.
- Ventajas
  - Permite mantener un reducido factor de carga para que las principales operaciones (insertar, buscar, eliminar) se realicen en tiempo constante.
- Inconvenientes
  - Requiere construir un nuevo array e insertar nuevamente todos los datos



# Rehashing en una Tabla Hash

- Si el Factor de Carga (grado de ocupacion) de una Tabla Hash es alto ( $>75\%$ ), el numero de colisiones aumenta significativamente.
- Solucion : Rehashing
  - Aumentar el tamaño de la tabla para reducir el factor de carga.
- Ventajas
  - Permite mantener un reducido factor de carga para que las principales operaciones (insertar, buscar, eliminar) se realicen en tiempo constante.
- Inconvenientes
  - Requiere construir un nuevo array e insertar nuevamente todos los datos

# Rehashing en una Tabla Hash

- Si el Factor de Carga (grado de ocupacion) de una Tabla Hash es alto ( $>75\%$ ), el numero de colisiones aumenta significativamente.
- Solucion : Rehashing
  - Aumentar el tamaño de la tabla para reducir el factor de carga.
- Ventajas
  - Permite mantener un reducido factor de carga para que las principales operaciones (insertar, buscar, eliminar) se realicen en tiempo constante.
- Inconvenientes
  - Requiere construir un nuevo array e insertar nuevamente todos los datos

# Rehashing en una Tabla Hash

- Si el Factor de Carga (grado de ocupacion) de una Tabla Hash es alto ( $>75\%$ ), el numero de colisiones aumenta significativamente.
- Solucion : Rehashing
  - Aumentar el tamaño de la tabla para reducir el factor de carga.
- Ventajas
  - Permite mantener un reducido factor de carga para que las principales operaciones (insertar, buscar, eliminar) se realicen en tiempo constante.
- Inconvenientes
  - Requiere construir un nuevo array e insertar nuevamente todos los datos

# Busqueda Mediante Hashing

- Permite aumentar la velocidad de búsqueda sin necesidad de tener los elementos ordenados.
- Cuenta también con la ventaja de que el tiempo de búsqueda es prácticamente independiente del número de componentes del arreglo.
- Para realizar la busqueda mediante este metodo bastara con conocer la clave asignada, por la funcion hash, a cada elemento.
- Al contrario de una busqueda convencional no debera recorrer el arreglo casilla por casilla, obtendremos el elemento directamente ingresando la clave.

# Busqueda Mediante Hashing

- Permite aumentar la velocidad de búsqueda sin necesidad de tener los elementos ordenados.
- Cuenta también con la ventaja de que el tiempo de búsqueda es prácticamente independiente del número de componentes del arreglo.
- Para realizar la busqueda mediante este metodo bastara con conocer la clave asignada, por la funcion hash, a cada elemento.
- Al contrario de una busqueda convencional no debera recorrer el arreglo casilla por casilla, obtendremos el elemento directamente ingresando la clave.

# Busqueda Mediante Hashing

- Permite aumentar la velocidad de búsqueda sin necesidad de tener los elementos ordenados.
- Cuenta también con la ventaja de que el tiempo de búsqueda es prácticamente independiente del número de componentes del arreglo.
- Para realizar la busqueda mediante este metodo bastara con conocer la clave asignada, por la funcion hash, a cada elemento.
- Al contrario de una busqueda convencional no debera recorrer el arreglo casilla por casilla, obtendremos el elemento directamente ingresando la clave.

# Busqueda Mediante Hashing

- Permite aumentar la velocidad de búsqueda sin necesidad de tener los elementos ordenados.
- Cuenta también con la ventaja de que el tiempo de búsqueda es prácticamente independiente del número de componentes del arreglo.
- Para realizar la busqueda mediante este metodo bastara con conocer la clave asignada, por la funcion hash, a cada elemento.
- Al contrario de una busqueda convencional no debera recorrer el arreglo casilla por casilla, obtendremos el elemento directamente ingresando la clave.

# Busqueda Mediante Hashing

- Permite aumentar la velocidad de búsqueda sin necesidad de tener los elementos ordenados.
- Cuenta también con la ventaja de que el tiempo de búsqueda es prácticamente independiente del número de componentes del arreglo.
- Para realizar la busqueda mediante este metodo bastara con conocer la clave asignada, por la funcion hash, a cada elemento.
- Al contrario de una busqueda convencional no debera recorrer el arreglo casilla por casilla, obtendremos el elemento directamente ingresando la clave.



# Conclusiones

- La Tabla Hash permite que el coste medio de las operaciones insertar, buscar y eliminar sea constante.
- Hay que elegir correctamente la funcione de hash:
  - Debe ser facilmente calculable, sin costosas operaciones.
  - Debe tener una buena distribucion de valores entre todas las componentes de la tabla.
- Ejemplos de Aplicacion de Tablas de Dispersion:
  - Corrector Ortografico.
  - Tablas de Simbolos de un Compilador.
  - Diccionarios.
  - etc.

# Conclusiones

- La Tabla Hash permite que el coste medio de las operaciones insertar, buscar y eliminar sea constante.
- Hay que elegir correctamente la funcione de hash:
  - Debe ser facilmente calculable, sin costosas operaciones.
  - Debe tener una buena distribucion de valores entre todas las componentes de la tabla.
- Ejemplos de Aplicacion de Tablas de Dispersion:
  - Corrector Ortografico.
  - Tablas de Simbolos de un Compilador.
  - Diccionarios.
  - etc.

# Conclusiones

- La Tabla Hash permite que el coste medio de las operaciones insertar, buscar y eliminar sea constante.
- Hay que elegir correctamente la funcione de hash:
  - Debe ser facilmente calculable, sin costosas operaciones.
  - Debe tener una buena distribucion de valores entre todas las componentes de la tabla.
- Ejemplos de Aplicacion de Tablas de Dispersion:
  - Corrector Ortografico.
  - Tablas de Simbolos de un Compilador.
  - Diccionarios.
  - etc.

# Conclusiones

- La Tabla Hash permite que el coste medio de las operaciones insertar, buscar y eliminar sea constante.
- Hay que elegir correctamente la funcione de hash:
  - Debe ser facilmente calculable, sin costosas operaciones.
  - Debe tener una buena distribucion de valores entre todas las componentes de la tabla.
- Ejemplos de Aplicacion de Tablas de Dispersion:
  - Corrector Ortografico.
  - Tablas de Simbolos de un Compilador.
  - Diccionarios.
  - etc.

# Bibliografía I



Paginas de Referencia.



<http://www.youtube.com/watch?v=WnLdu8OHA3Q>



<http://www.hci.uniovi.es/Products/DSTool/hash/hash-queSon.html>



<http://juan-pato.blogspot.com/2009/05/metodo-de-busqueda-hashing.html>